Contents

IQP 生成模型於强重力透鏡影像 **1**

摘要 . . . 1

1 引言 . . . 2

2 實驗設定 . . . 2

3 結果 . . . 3

3.1 透鏡影像是地圖上最適合 IQP 的資料集 . . . 3

3.2 原流程為何需要學到的方向 . . . 4

3.3 學到的潛變數方向能夠泛化 . . . 4

3.4 原論文式比較與資料量縮放 . . . 5

4 討論與限制 . . . 5

附錄 **6**

附錄 A 管線流程 . . . 6

附錄 B 原論文湍流實驗的重現 . . . 6

附錄 C 支撐集不匹配（原論文圖 3） . . . 8

附錄 D I_{QCLI}−I_{CCI} 上限 . . . 9

附錄 E 附加實驗組 . . . 10

附錄 F 各類別樣本 . . . 11

翻譯說明 . . . 12

固定譯法表 . . . 12

IQP 生成模型於强重力透鏡影像

本文為 NeurIPS ML4PS 2026 投稿稿 v11（`paper/ml4ps2026/v11/main.tex`）的繁體中文翻譯，供作者與合作者閱讀，非投稿用版本。逐段忠實翻譯，未增刪內容、未更動任何數字。

摘要

瞬時量子多項式（instantaneous quantum polynomial, IQP）電路一般認為難以用古典方法取樣 [Bremner 等 2011; Bremner 等 2016]，而最大平均差異（MMD）損失所需的期望值仍保持可計算，因此這樣的 Born machine 可以在古典端訓練、再部署到量子硬體上 [Recio-Armengol 等 2025]。近期提出的相關性—複雜度地圖，由資料集的 Walsh 階譜與其多重資訊（multi-information）算出兩個指標，用來預測哪些資料集適合這類模型；而 DeepLense 强重力透鏡影像正位於我們量測過最適合 IQP 的位置（18 位元三元組為 0.47、0.87；我們用來訓練的 10 位元裁切 pmf 為 0.47、0.43），高於當初提出這張地圖時所用的湍流資料。只要給定「學到的」潛變數方向 $\theta = \theta^0 + \Phi^\top z$，在透鏡裁切影像上的 10 量子位元模型，在 11 張訓練影像時足以與參數量多出 2 至 39 倍的 RBM 與 DCGAN 相競爭、並在部分指標上與之相當，同時能以 0.9684 ± 0.0004 的相關度重建未見過的影像。有三點保留條件為此設下界線。原論文流程中固定的潛變數區塊只產生雜訊；一個結構相符的置換零模型仍得到 $I_{\mathrm{QCLI}} = 0.42$；而在 100 張影像時 DCGAN 領先，正如原論文所預測。所有結果都是 $n = 10$ 量子位元下、跨五個隨機種子的精確古典模擬，因此我們不宣稱任何量子優勢。

符號說明：原文以巨集定義 $I_{\mathrm{QCLI}} \equiv I_{\mathrm{QCLI}}$ 與 $I_{\mathrm{CCI}} \equiv I_{\mathrm{CCI}}$，本譯文一律直接寫成 I_{QCLI} 與 I_{CCI}。

---

1 引言

IQP 電路是由互相對易的閘所構成的電路，其輸出分布為某個相位函數的 Walsh–Hadamard 變換的平方。若能對它們做精確的古典取樣，多項式階層就會塌縮 [Bremner 等 2011]，而且一般猜想這種困難性在近似取樣下仍然成立 [Bremner 等 2016]，不過足夠的雜訊會恢復古典可模擬性 [Rajakumar 等 2024]，而且對某些 IQP 實例已存在古典演算法 [Codsi 與 van de Wetering 2025]。同樣的對易結構讓 MMD 損失的期望值保持可計算，因此這類模型可以「在古典端訓練、在量子硬體上部署」[Recio-Armengol 等 2025; Recio-Armengol 與 Bowles 2025]。

真實資料是否落在那個有用的位置上，是一個實證問題，而近期的一項提案 [Liu 等 2026] 用兩個要素來處理它。(i) 一張「相關性–複雜度地圖」，把資料集放到兩個座標上：量子相關似然指標（quantum correlation-likeness indicator）I_{QCLI}，即資料的 Walsh 階譜與獨立同分布二項基準 $b_k = \binom{n}{k}/2^n$ 之間的 Jensen–Shannon 散度；以及古典相關複雜度指標（classical correlation-complexity indicator）I_{CCI}，即最佳成對樹漏掉了多少總相關性 [Watanabe 1960; Schneidman 等 2003; Chow 與 Liu 1968]，而高 I_{QCLI}、高 I_{CCI} 的角落就是 IQP 電路應當表現良好之處。(ii) 一套潛變數調適流程（原論文的 Algorithm 1：先在單一錨點上訓練一個共用的相位核心，接著逐一樣本地調適一組依 Hamming 順序取出的、固定的 50 個 Walsh 基底相位，再對它做內插以觸及未見過的樣本）。兩者都只在 $n = 18$ 量子位元下的二維湍流快照上示範過 [Khojasteh 等 2022]。

我們把這兩者都搬到 DeepLense [Alexander 等 2020a; Alexander 等 2020b] 的模擬暗物質強重力透鏡影像上。透鏡裁切影像落在這張地圖上最適合 IQP 的位置；在其上訓練的 10 量子位元 IQP Born machine，在 11 張影像時以少 2 至 39 倍的參數量在兩項指標上都足以與該論文自己的 RBM 與 DCGAN 基準相競爭，而且唯有把該流程中固定的 Walsh 潛變數區塊改成「可學習」之後才達得到這個水準。附錄 B 至附錄 D 把同一批測試搬回原論文自己的資料上，其湍流結果在我們預先登錄的慣例下無法重現，另有兩項內部主張的結果好壞參半。

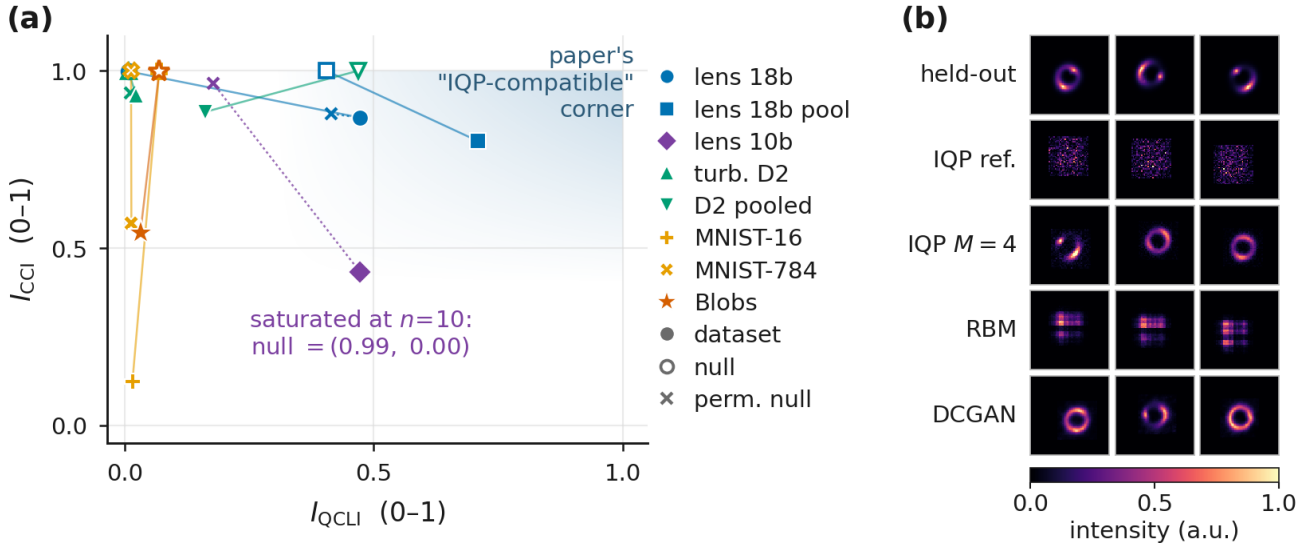


圖 **1**：**(a)** 相關性–複雜度地圖，資料集以實心標記表示，獨立均勻零模型以空心標記表示並標為 null，置換零模型以叉號表示（本工作所加，原論文中沒有）。圖例中 lens 18b 與 18b pool 為 18 位元的每張影像編碼與其池化編碼，lens 10b 為 10 位元裁切 pmf，turb. D2 與 D2 pooled 為原論文的湍流資料，MNIST-16 與 MNIST-784 為 4×4 與 28×28 的 MNIST，Blobs 為 BinaryBlobs。**(b)** 每個模型的前三個非條件生成樣本，N=100，未經挑選，共用 0–1 色階。

---

2 實驗設定

模型。我們把原流程拿來與以下兩者比較：一是把它那組固定的 50 個相位改成跨影像「聯合」訓練，二是我們的「學到的方向」模型，也就是一個可訓練的 Φ，其中有 M 個相位空間中的方向，於是每張影像都是 M 維空間中的一個點 z_i，

$$\theta_i \;=\; \theta^0 + \Phi^{\top} z_i, \qquad \theta^0 \in \mathbb{R}^{1024}, \quad \Phi \in \mathbb{R}^{M\times 1024}, \quad z_i \in \mathbb{R}^{M} \tag{1}$$

其中表 2 中 M=4，而圖 2(a) 的掃描中 $M \in \{0, 2, 4, 6, 8, 16\}$；$\Phi$ 的每一列都做 L^2 正規化到 $\sqrt{1024}$，並對 z 施加相對的 L^2 懲罰 $\lambda = 10^{-3} L_0$（M=8 這一組提高到 $0.3 L_0$），其中 L_0 是在 θ^0 與 $z = 0$ 處的資料損失。目標函數為原論文核

（原論文取自 IQPopt 的多頻寬高斯 MMD 核 [Recio-Armengol 與 Bowles 2025]，由於該論文未給出頻寬規則，我們沿用該函式庫的規則，見附錄 E）、平坦 MMD（均等的 Walsh 權重，可由硬體取樣次數估計）以及精確 KL（僅限模擬使用）；z 由擬合的高斯分布抽取，或以抖動重新取樣，而 θ^0 則以 1,000 步的精確 KL 做暖啓動，這一步本身同樣僅限模擬使用。

基準模型與指標。基準模型為一個受限波茲曼機（restricted Boltzmann machine, RBM；10 個可見單元與 1,000 個隱藏單元，採用單步 Gibbs 的持續對比散度 [Hinton 2002; Tieleman 2008]）以及一個深度卷積生成對抗網路（deep convolutional generative adversarial network, DCGAN）[Radford 等 2015]，其參數規模列於表 2；兩者都在 200 張與留出集互斥的驗證影像上做驗證集提前停止（RBM 為 160k 或 80k 步，DCGAN 為 5k 至 30k 步），而 IQP 實驗組則固定跑 4,000 步，這一點只會對它們有利。我們沿用原論文的兩項指標，即強度直方圖之間的 Jensen—Shannon 散度（PDF—JS），以及 Conv2D-MMD^2，也就是在一個固定隨機卷積編碼器特徵空間中的有偏 V 統計量 [Gretton 等 2012]，並加上一項留出集的投影相關。PDF—JS 使用固定在 $[0, 1]$ 上的 50 個分箱，而 Conv2D-MMD^2 的尺度與頻寬僅取自留出集，因此兩項指標都不會隨著被評分的實驗組而變動；下限則來自 20 次抽樣，每次以 200 張對照 200 張互斥的驗證影像（附錄 E）。每一個 IQP 實驗組與 RBM 都共用通量純量 S，而 DCGAN 自行學習其尺度，因此未對齊的 Conv2D-MMD^2 有一部分是在比較亮度，我們也另外加上一個通量對齊的版本並標示為事後分析，作法是把每一張影像重新縮放到留出集的平均總強度。每一組都在 $N \in \{11, 100\}$ 下生成 200 張影像，並對照同樣的 200 張留出影像評分，所有數值皆為跨五個隨機種子的平均值 $\pm$ 樣本標準差，而投影相關則由八次重啓中最佳化 z（附錄 E）。

與原論文設定的差異。有六項選擇與原論文不同，每一項都源自資料本身。原論文的快照要內插到未見過的時間點，而我們所使用的 DeepLense `Model II` 影像 [Alexander 等 2020a; Alexander 等 2023; ML4SCI Collaboration 2025] 是靜態的、分成三個類別，因此我們從潛變數先驗做非條件生成。它把一個樣本編碼成 18 位元的 $(x, y, \text{intensity})$ 三元組，而我們則把每張 64×64 影像對齊質心，並把其中央 32×32 的裁切（佔全部光量的 99.4%）讀成 $n = 10$ 之下、涵蓋 1,024 個格點的單一機率質量函數（pmf）（附錄 A），因為原始的強度軸所攜帶的資訊僅略多於一個位元。它的「錨定並調適」流程把潛變數區塊固定住，而我們則學習 Φ 並把 N 張影像聯合訓練（3.2 節）；而且它每一步由 500 個樣本估計其 MMD，而 10 量子位元的 pmf 是精確的。它留出的是時間點，而靜態影像沒有時間點，因此我們改為投影到留出影像上。每一張生成的裁切影像都以訓練集的平均總強度 S（N=11 時為 112.3、N=100 時為 124.9；留出集為 123.9）與一個訓練集的位移貼回 64×64。

---

3 結果

3.1 透鏡影像是地圖上最適合 IQP 的資料集

表 1 重新計算了這張地圖。以原論文編碼湍流的方式來編碼時，透鏡影像的 I_{QCLI} 遠高於湍流，落在地圖所稱的 IQP 相容角落之內；然而一個保留每張影像強度直方圖、並摧毀所有空間結構的置換零模型，其分數也幾乎與它們相當，而湍流資料的表現也是一樣，因此在這種編碼下，這張地圖大致上只是在追蹤直方圖。只有我們用來訓練的 10 位元裁切 pmf 在兩個座標上都與其零模型分離開來，所以有利的位置是必要條件而非充分條件。

表 **1**：我們資料上的相關性—複雜度地圖，每一個置換零模型都保留上一列的數值直方圖，數值為跨五個隨機種子的平均值 $\pm$ 標準差。K 是每張影像或每個快照的 n 位元編碼數量；透鏡 18 位元那一列掃過 64×64 影像全部 4,096 個 (k_x, k_y) 格點，因此沒有取樣噪音，而湍流那一列則是從更大的網格上做次取樣。兩者都與 K 有關，所以每一列只能對照它自己相同 K 的零模型來讀；而在原論文自己的 $K = 5 \times 10^4$ 之下，湍流的 I_{QCLI} 為 0.091 ± 0.000，其零模型為 0.098 ± 0.001。

資料集與編碼	K	I_{QCLI}	I_{CCI}
透鏡，18 位元 $(x, y, \text{intensity})$ 三元組	4,096	0.4715 ± 0.0000	0.8677 ± 0.0000
置換零模型	4,096	0.4154 ± 0.0000	0.8783 ± 0.0001
湍流 D2，18 位元三元組	4,096	0.0232 ± 0.0002	0.9285 ± 0.0008
置換零模型	4,096	0.0114 ± 0.0000	0.9371 ± 0.0009
透鏡，10 位元裁切 pmf	精確 pmf	0.4731 ± 0.0000	0.4313 ± 0.0000
置換零模型	精確 pmf	0.1782 ± 0.0000	0.9634 ± 0.0004

3.2 原流程為何需要學到的方向

在我們低變異的潛變數區塊上循序執行時，Algorithm 1 產生的是雜訊（圖 1(b) 第二列；依 Hamming 順序排列的版本見附錄 E）。原因不在可表達性，因為完整的 1,024 相位電路在平坦 MMD 下能把「單一」一張對齊裁切影像擬合到 0.99997 ± 0.00001 的相關度。原因在流程本身。當核心被凍結在單一錨點上時，那 50 個固定的潛變數座標重建其他每一張訓練影像時只有 0.44 ± 0.04，因為固定的 Walsh 方向的作用像是一種 XOR 位移干涉圖樣，只會在像素之間做交叉淡化，而不會移動透鏡結構。

3.3 學到的潛變數方向能夠泛化

式 (1) 修好了這個問題。凍結 θ^0 與 Φ、只在 200 張「留出」影像上最佳化 z 時，N=100 的最佳實驗組（M=4 的平坦 MMD）達到 0.9684 ± 0.0004 的平均相關度，對照最近鄰訓練影像的參考值 0.970，而原論文核在 N=11 時只達到 0.792 ± 0.006、在 N=100 時只達到 0.805 ± 0.012。這個增益來自學習方向本身，而不是來自額外的參數，因為在圖 2(a) 的 N=20 掃描中，訓練過的 Φ 勝過在同一個無潛變數偏移上的隨機方向（0.7458 ± 0.0005）。有用的 M 也一直維持在很小的範圍，M=2 是最好的、也遠比其他穩定（0.9060 ± 0.0021 對照 M=4 的 0.8577 ± 0.0559），而到 M=8 就崩潰（0.218 ± 0.121），因為此時所需的 $\|z\|$ 超過了同調半徑。

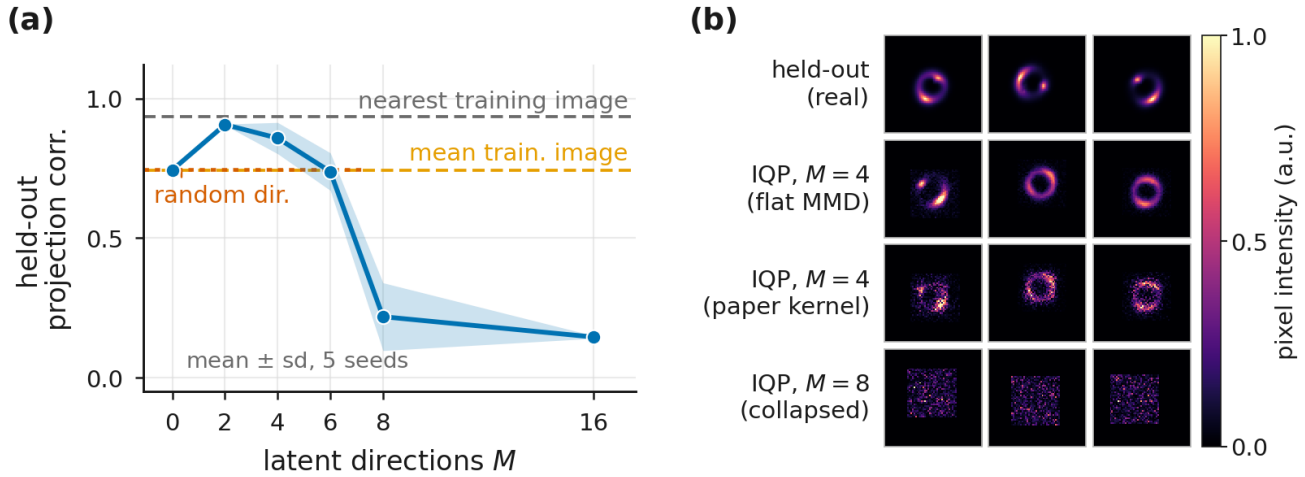


圖 **2**：不同的實驗。**(a)** 受控的潛變數寬度掃描（N=20），留出集投影相關對 M 作圖，數值為跨五個模型隨機種子的平均值 ± 標準差，並附上其自身的參考水準（最近鄰訓練影像 0.934、平均訓練影像 0.744、在無潛變數的 M=0 偏移上的隨機方向 0.746）；M=8 與 16 兩個點取自一次學習率掃描中、依所繪相關度選出的最佳值，而 M=0 與 M=4 為單一學習率。**(b)** N=100 的 Round-3b 各實驗組，先是留出裁切影像，接著依序是 M=4 的平坦 MMD、M=4 的原論文核，以及崩潰的 M=8 實驗組。

表 **2**：在透鏡裁切影像上的原論文式比較，數值為跨五個隨機種子的平均值 ± 標準差，PDF—JS 以 10^{-3} 為單位，兩個 MMD^2 欄位以 10^{-2} 為單位。數值越低越好；粗體標示平均值最佳、且領先次佳者的幅度大於兩者各自標準差的項目，因此沒有粗體的欄位代表其勝負無法由種子離散度支持。參數量為 N=11 / N=100 的總數；$\mathrm{MMD}^2_{\mathrm{al}}$ 是通量對齊的版本（事後分析），最後一列是 20 次抽樣、每次 200 張對照 200 張的真實對真實下限。† 與參數計算慣例見附錄 E。

模型	參數量	$N=11$ PDF—JS	$N=11$ MMD^2	$N=11$ $\mathrm{MMD}^2_{\mathrm{al}}$	$N=100$ PDF—JS	$N=100$ MMD^2	$N=100$ $\mathrm{MMD}^2_{\mathrm{al}}$
IQP，原論文流程（Alg. 1）†	1,524 / 5,974	7.2 ± 0.7	18.8 ± 1	22.5 ± 2	8.4 ± 0.4	21.8 ± 0.6	26.6 ± 0.7
IQP，固定基底，聯合訓練	1,524 / 5,974	1.6 ± 0.4	12.3 ± 0.4	12.5 ± 1	1.0 ± 0.1	10.2 ± 0.8	8.5 ± 1

模型	參數量	$N=11$ PDF—JS	$N=11$ MMD^2	$N=11$ $\mathrm{MMD}^2_{\mathrm{al}}$	$N=100$ PDF—JS	$N=100$ MMD^2	$N=100$ $\mathrm{MMD}^2_{\mathrm{al}}$
IQP，學到的方向 M=4（平坦 MMD）	5,164 / 5,520	3.0 ± 0.2	8.9 ± 0.2	2.7 ± 0.2	2.9 ± 0.3	7.2 ± 0.3	2.6 ± 0.4
IQP，學到的方向 M=4（原論文核）	5,164 / 5,520	0.81 ± 0.05	9.6 ± 0.3	7.4 ± 0.6	1.4 ± 0.2	11.3 ± 0.5	10.0 ± 0.8
RBM [Tieleman 2008]	11,510 / 15,960	1.7 ± 0.8	6.5 ± 0.8	11.1 ± 4	0.9 ± 0.1	5.9 ± 0.4	8.1 ± 2
DCGAN [Radford 等 2015]	199,837	1.1 ± 0.6	5.1 ± 2	3.9 ± 1	**0.55** ± 0.12	**2.2** ± 0.3	2.1 ± 0.4
真實對真實下限	n/a	*0.04* ± 0.02	*0.5* ± 0.3	*0.4* ± 0.2	*0.04* ± 0.02	*0.5* ± 0.3	*0.4* ± 0.2

3.4 原論文式比較與資料量縮放

在表 2 中，十一張影像的情境才是 IQP 實驗組具競爭力的地方。M=4 的原論文核實驗組在該處持有最佳的平均 PDF—JS，而 M=4 的平坦 MMD 實驗組持有最佳的平均通量對齊 Conv2D-MMD^2，所用參數量少了 2 至 39 倍，不過兩項領先都落在基準模型的一個標準差之內，因此我們把它們讀成相當，而不是勝過。未對齊的 Conv2D-MMD^2 在兩種大小下都走向相反，兩個基準模型都領先每一個 IQP 實驗組，這個排序在通量對齊的欄位中被部分反轉。在 N=100 時，DCGAN 在三個欄位上都領先，其中 PDF—JS 與未對齊的 Conv2D-MMD^2 是決定性的領先，而在通量對齊的那一欄則落在 M=4 平坦 MMD 實驗組的離散度之內。這個排序正是原論文的資料量縮放圖像，其跨 N 的軌跡見圖 5。在單一類別內訓練時，同一個實驗組維持 0.969 至 0.972 的投影相關，而 PDF—JS 與 Conv2D-MMD^2 則維持在合併訓練的水準，每一項各自對照它自己的下限（表 4）。

---

4 討論與限制

本文沒有任何內容構成量子優勢的證據，因為每一個電路都是在 $n = 10$ 量子位元下精確模擬，而那些困難性結果所描述的是規模化之後的模型類別，而不是我們的這些實例。五個隨機種子並不算多，而且 DCGAN 在某一個設定與某一個種子上，於未對齊的 Conv2D-MMD^2 上帶來高達 57%、於 PDF—JS 上高達 74% 的離散度，因為 cuDNN 沒有確定性的轉置卷積核心。S 是強加在 IQP 實驗組與 RBM 上的，而 DCGAN 則是自行學習它。

附錄

附錄 A 管線流程

圖 3 總結了編碼方式、潛變數參數化與評估流程。

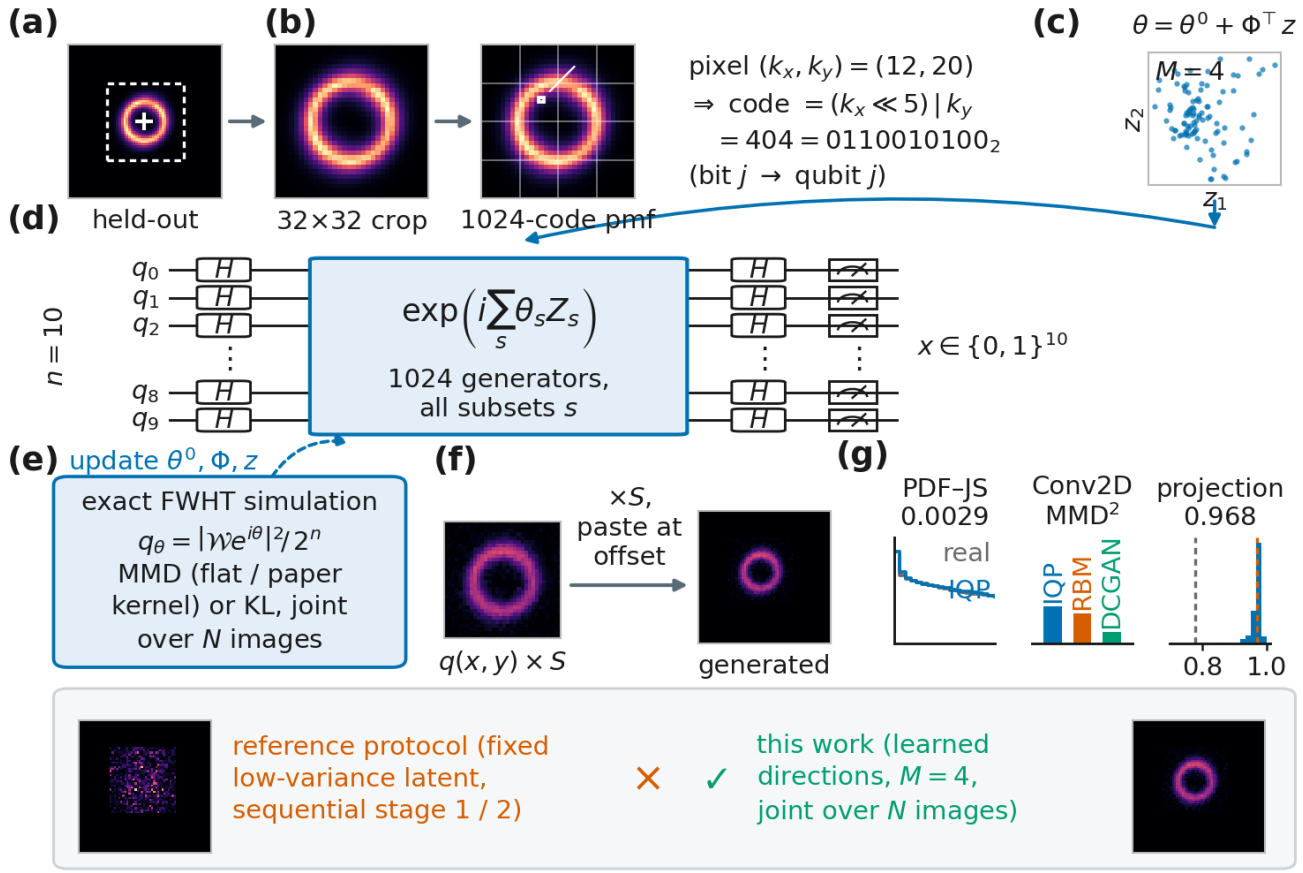


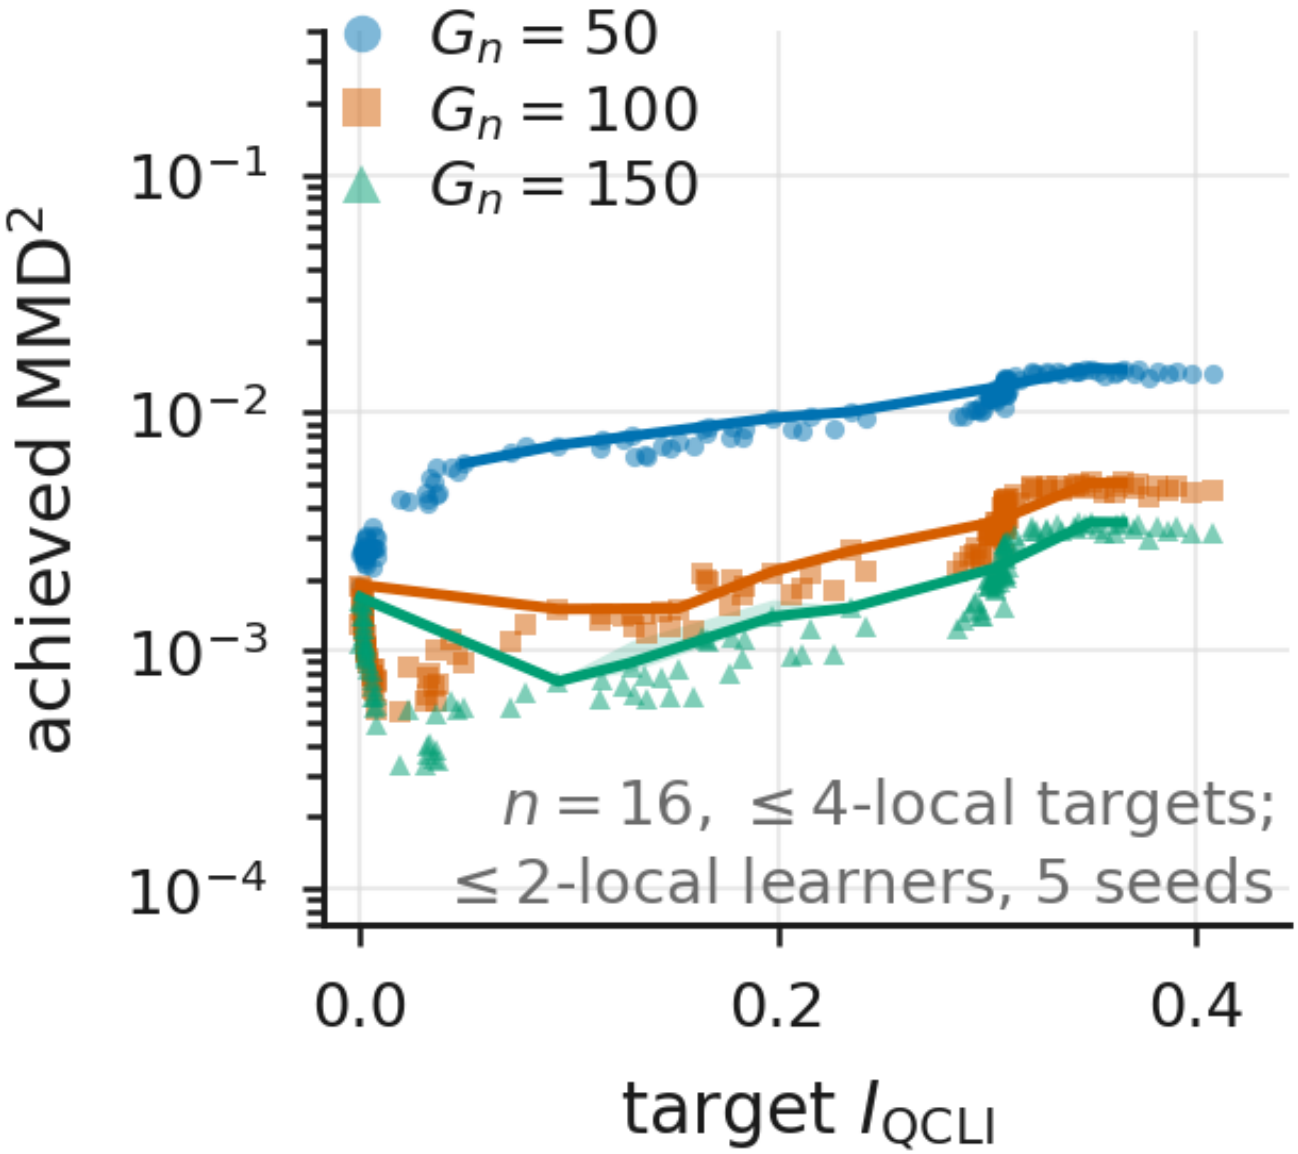
圖 **3**：管線流程。**(a)** 一張留出的 64 × 64 影像，白色十字位於其強度質心，虛線框為 32 × 32 的裁切視窗。**(b)** 對齊後的裁切影像被讀成涵蓋 1,024 個格點的 pmf，其中範例像素 $(k_x, k_y) = (12, 20)$，即 (x, y) 的整數形式，帶有編碼 $404 = 0110010100_2$，而位元 j 定址到量子位元 j。**(c)** $M = 4$ 時 100 張訓練影像的前兩個學到的潛變數座標。**(d)** IQP 電路：一層 H 閘、一個涵蓋全部 1,024 個子集 s 的對角相位 $\exp(i \sum_s \theta_s Z_s)$、第二層 H 閘與測量。**(e)** 透過 $q_\theta = |\mathcal{W} e^{i\theta}|^2 / 2^n$ 做精確模擬，以 MMD（平坦核或原論文核）或以 KL 在 N 張影像上聯合訓練，其中快速 Walsh–Hadamard 變換（FWHT）提供 $\mathcal{W}$，虛線箭頭則表示更新 θ^0、Φ 與 z。**(f)** 訓練後的 $q(x, y)$ 乘上 S 並貼在一個取樣得到的位移處。**(g)** 真實樣本與 IQP 樣本的強度 PDF（PDF–JS 0.0029）、N=100 時的 Conv2D-MMD²（IQP 0.072、RBM 0.059、DCGAN 0.022），以及 200 張留出影像上的投影相關（平均 0.968）。最下面一列對比了一個原流程樣本與本工作 M=4 的樣本。

附錄 B 原論文湍流實驗的重現

我們在原論文自己的資料集（二維圓柱尾流湍流 D2 [Khojasteh 等 2022]，$n = 18$ 量子位元，11 張錨點快照）上、跨五個隨機種子嘗試了直接重現。在我們預先登錄的慣例下，結果是未能重現，因為在 11 張快照的情境中，RBM（PDF–JS 0.217 ± 0.007）與一個 1.2M 參數的 DCGAN（0.045 ± 0.062）在「兩項」指標上都勝過我們 31k 參數的 IQP（0.272 ± 0.004）。有兩項發現為此加上但書。在一種原論文從未指明的「後寫覆蓋」（last-write-wins）彙整慣例下，我們 IQP 的 PDF–JS 數值確實落在已發表數值的附近（0.0324 ± 0.0011 與 0.0473 ± 0.0005，對照 0.0238 與 0.0221，其 Conv2D-MMD² 為 0.711 ± 0.012 與 0.738 ± 0.017），但 RBM 仍然勝出。Conv2D-MMD² 在該處也已經飽和，因為在像素空間中打亂的真實資料就已經得到 0.7045 ± 0.0095，低於原論文表 2 中的每一個模型（0.90 至 1.47），而且合成未見過時間點的任務用線性內插即可解決（0.9998，確定性）。我們錨點擬合的水準（31k 那一組為取樣 0.651 ± 0.010、精確 0.739 ± 0.010）可追溯到第 1 階段凍結潛變數區塊（-0.114 ± 0.021），以及一個不帶隨機種子的 0.892 模型族上限（該次

擬合中沒有任何步驟消耗隨機數流），而非我們的實作；至於那個 5×10^4 樣本的 pmf，曾因單一隨機種子而看似是第二個成因，但在五個種子上其代價已小到量不出來（-0.001 ± 0.022），而第 2 階段則帶來 0.000 ± 0.000。

附錄 **C** 支撐集不匹配（原論文圖 **3**）



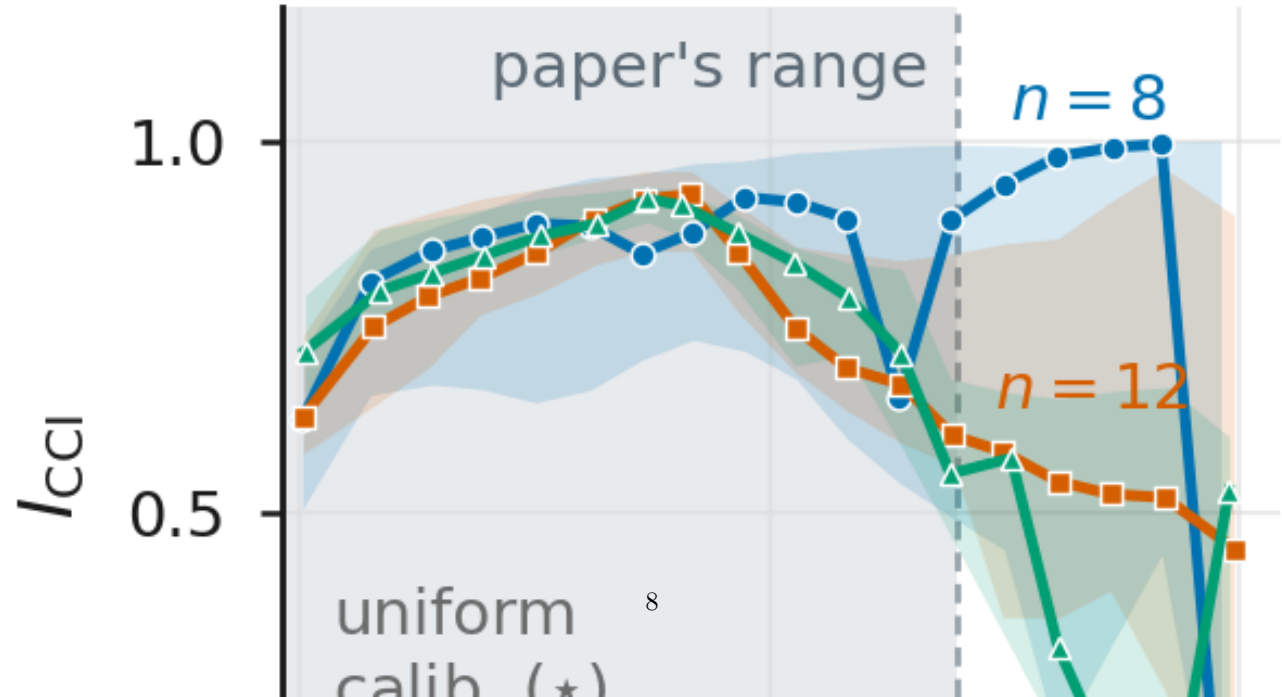


圖 **4**：**(a)** $n = 16$ 的支撐集不匹配研究，140 個目標電路（$\leq$ 4-local）涵蓋精確 $I_{\mathrm{QCLI}} \in [0, 0.408]$，由請求閘數 $G_n = 50$、100 與 150 的 $\leq$ 2-local 學習器擬合，其中 G_n 是學習器的閘數，最後一個被截在 $n = 16$ 時 $\leq$ 2-local 電路所具有的 136 個生成元（精確 MMD、Adam、5,000 步、五個學習器隨機種子）。閘數越多，整條包絡線就越低（主張 (b)，可重現），而在可達到的範圍內，達成的 MMD^2 反而隨目標的 I_{QCLI}「上升」，與主張 (a) 相反。**(b)** 只以最大化 I_{QCLI} 為目標而最佳化的電路，$n = 8, 12, 16$，每個 n 有五個隨機種子與 2 種增益設定，各執行 3,333 步，每個 n 約記錄 33,000 個點。I_{CCI} 從未進入目標函數。

原論文的圖 3 主張：(a) 可達成的 MMD 的上包絡線會隨著目標的 I_{QCLI} 上升而下降，因為支撐集所導致的下限縮小了；(b) 學習器的閘數越多，整條包絡線就整體下移（圖 4(a)）。主張 (b) 可以重現，因為三種學習器所達成的 MMD^2 中位數依序下降為 $9.58 \times 10^{-3} \to 2.15 \times 10^{-3} \to 1.44 \times 10^{-3}$，其種子離散度至多為 2×10^{-5}。主張 (a) 在我們能達到的範圍內則走向相反，因為當目標的精確 I_{QCLI} 從 0 增加到 0.41 時，達成的 MMD^2 反而「上升」（Spearman $\rho = +0.979 \pm 0.001 / +0.901 \pm 0.001 / +0.809 \pm 0.004$），這個趨勢在一個以精確 pmf 訓練的對照組上同樣成立。該論文的前提在機制上仍然成立（Proposition II.2 下限代理量的精確 pmf 形式 $\rho \leq -0.98$、其 10^4 樣本形式 ≤ -0.92），但達成的 MMD 主要受可訓練性支配，而非受支撐集不匹配支配。我們的目標電路族在精確 $I_{\mathrm{QCLI}} \approx 0.41$ 處飽和，若照該論文的做法以 10^4 個樣本估計則飽和在 0 至 0.064，因此主張 (a) 所斷言的區間落在我們所能建構的範圍之外。

附錄 D I_{QCLI}—I_{CCI} 上限

我們也重現了「只最大化 I_{QCLI} 就會附帶提高 I_{CCI}」的那個實驗（圖 4(b)）。這種耦合在低 I_{QCLI} 處可以重現（限制在 $I_{\mathrm{QCLI}} \leq 0.3$ 時，$n = 8/12/16$ 的合併 Spearman $\rho = +0.79 / +0.79 / +0.90$，逐個種子則為 $+0.92 \pm 0.10 / +0.91 \pm 0.04 / +0.96 \pm 0.01$），但在五個種子合併之後，三種大小都在 $I_{\mathrm{QCLI}} \approx 0.38$ 以上反轉（整體 $\rho = +0.08, -0.57, -0.64$），而在兩個較小的尺寸上，逐個種子的整體 ρ 本身就依種子而異（$+0.25 \pm 0.92$ 與 -0.52 ± 0.36），因為一條軌跡能否在 3,333 步之內抵達上限是隨機種子的性質。這個反轉是由定義本身所強制造成的，因為完全均勻的分布會使 I_{QCLI} 最大化（0.982/0.998/0.9999），而其 $I_{\mathrm{CCI}} = 0$。原論文的圖停在 $I_{\mathrm{QCLI}} \approx 0.7$ 以下，因此高 I_{QCLI} 未必代表存在可利用的結構，也可能只是代表接近均勻分布。

附錄 **E** 附加實驗組

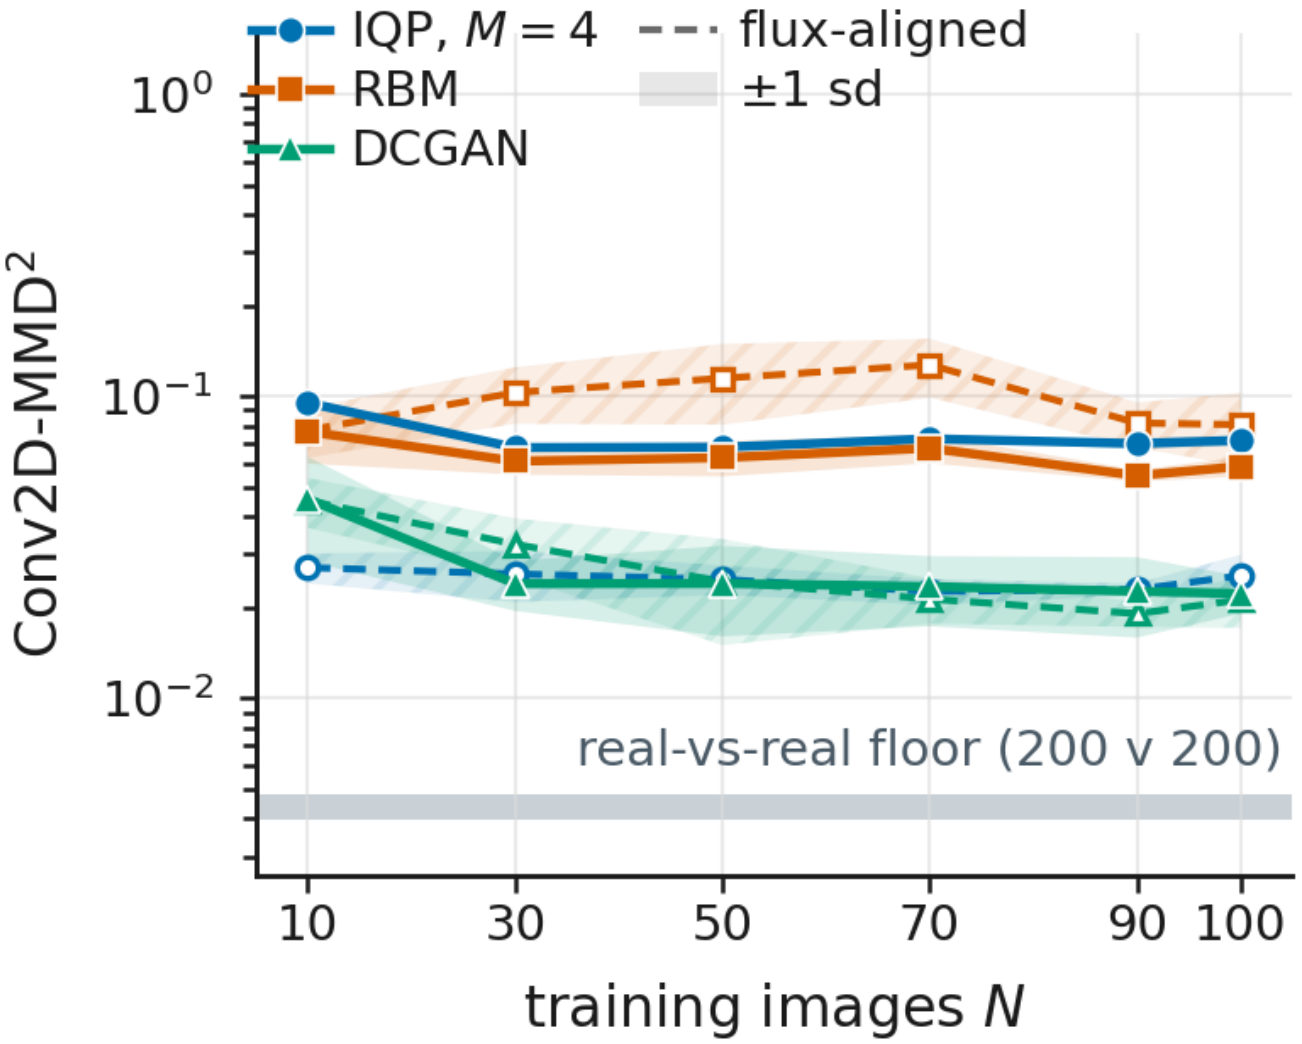


圖 **5**：Conv2D-MMD^2 對訓練集大小作圖，數值為跨五個隨機種子的平均值 ± 標準差，未對齊者為實線，通量對齊者為帶空心標記的虛線，繪於真實對真實下限的帶狀區域之上。隨機種子只改變模型，訓練子集則是同一次抽樣的巢狀前綴。

資料量縮放。在 $N \in \{10, 30, 50, 70, 90, 100\}$ 下，學到方向的 IQP 實驗組在 $N \geq 30$ 時保持平坦（未對齊的 Conv2D-MMD^2 為 0.068 至 0.072），RBM 也是如此（0.055 至 0.067），而 DCGAN 在 N=10 時就已經領先（0.046 ± 0.017 對照 0.095 ± 0.002），並在 N=100 時再降低 2 倍（$0.046 \to 0.022$），如圖 5 所示。在通量對齊的那一欄，IQP 實驗組在 N=10 與 N=30 領先，DCGAN 則從 N=50 起領先，兩者除了 N=10 與 N=90 之外，在各處都落在一個種子標準差之內而互相重疊。

精確 **KL**。 KL 需要完整的模擬分布，無法由硬體取樣次數估計，因此我們把它排除在表 2 之外，並在此僅以隨機種子 0 記錄。它的 M=2 實驗組使用 3,094 / 3,272 個參數，在 N=11 時 PDF—JS 為 0.00172、在 N=100 時為 0.00302，未對齊的 Conv2D-MMD^2 為 0.119 與 0.091，通量對齊者為 0.046 與 0.075。圖 2(b) 中崩潰的 M=8 實驗組同樣是一個 KL 實驗組。

M=2 的先驗抽樣。從 M=2 先驗抽出的樣本全都是環狀結構，均方根半徑為 9.40 ± 0.21 像素，對照真實資料的 9.21 ± 0.15，不過在橢率上的離散程度偏低（0.048 對照 0.099）。

其他實驗組。我們共回報 18 種條件：16 個 IQP 實驗組，以及 RBM 與 DCGAN 基準。表 2 以外的實驗組（依 Hamming 順序排列的潛變數區塊、其他目標函數與先驗、一個偽時間條件實驗組）都在已釋出的表格中以相同的指標評分。改為聯合訓練而非循序訓練之後，依 Hamming 順序排列的區塊在 N=11 時 PDF—JS 達到 0.00178、在 N=100 時達到 0.00175，這與「3.2 節中失敗的是循序流程，而不是區塊本身」一致；我們並未在循序流程下執行它。M=8 實驗組崩潰（N=100、隨機種子 0 時 PDF—JS 0.0102、MMD^2 0.241）。

表 **2** 的慣例。標記 † 的實驗組是在我們低變異的潛變數區塊上執行 Algorithm 1，其第 1 階段是把相位核心與錨點自身的潛變數區塊聯合訓練，而原流程則是凍結一個隨機的區塊。它的參數量欄位計入共用核心，加上各個 N 之下每張影像的潛變數區塊；DCGAN 那一項只計其生成器，其判別器另外帶有 53,497 個僅用於訓練的參數。RBM 同樣是一個聯合模型，其可見偏置與 40 個隱藏偏置是每張影像各有一份，因此它持有 10,960 個共用權重加上每張影像 50 個，其總數也隨 N 增長。把同一套驗證規則套用到 IQP 實驗組時，會選出 1k 至 16k 步，並且不會讓表 2 的任何一格變動超過一個標準差（在 v10 流程下，N=11 的原論文核 PDF–JS 從 0.92 改善到 0.78×10^{-3}，這是十六個比較中唯一分得開的一個）；我們保留固定 4,000 步的數值。

流程細節。原論文核是 IQPopt 函式庫 [Recio-Armengol 與 Bowles 2025] 的三頻寬高斯 MMD。生成的像素若落在 $[0, 1]$ 之外，會在 PDF–JS 之前被裁掉，被裁掉的質量至多為 6×10^{-3}；下限的抽樣則來自留出集切分之後剩下的 8,710 張驗證影像。該核心即為該函式庫在 $\sigma = \{0.989, 1.729, 2.236\}$ 時所用者，平均 Pauli 權重為 2.00、0.77 與 0.48；原論文採用了這個核，卻沒有公布頻寬，因此這些數值是依該函式庫的規則而來。Conv2D-MMD^2 的頻寬在留出特徵上一次固定，並由每張表的每一列共用，其值為未對齊 0.005547、通量對齊 0.002558。若把 θ^0 那 1,000 步的精確 KL 暖啓動改成在同一張平均裁切影像上的平坦 MMD 暖啓動，使每一個階段都可由取樣次數估計，則在兩種 N 之下都不會讓任何指標變動超過一個標準差。留出集投影的八次重啓中，我們保留與目標相關度最高的那一次，而以損失挑選的做法至多落後 0.005；單就零初始化的那一次重啓，在 N=11 時達到 0.899 ± 0.018、在 N=100 時達到 0.9684 ± 0.0004。DCGAN 是此處唯一無法逐位元重現的一組，因為 cuDNN 沒有確定性的轉置卷積核心，所以某一個設定在某一個種子上，於未對齊的 Conv2D-MMD^2 上相差達 57%、於 PDF–JS 上達 74%，而每一個訓練兩次的 RBM 與 IQP 設定都能精確重現。

固定預算下的基準模型。表 3 給出兩個基準模型在我們 round-3 流程固定 20,000 步之下的結果，並與表 2 中由驗證集選出的預算並列；提前停止對兩者都有幫助，其中 N=11 的 DCGAN 更達一個數量級以上。

表 **3**：兩個基準模型在固定 20,000 步之下對照其由驗證集選出的預算，數值為跨五個隨機種子的平均值 ± 標準差，並在 round-3 慣例下評分（分箱與編碼器頻寬依各實驗組設定），因此這兩欄只能互相比較，不能與表 2 比較。

實驗組	N	PDF–JS（$\times 10^{-3}$）20k 步	PDF–JS（$\times 10^{-3}$）選出的預算	MMD^2（$\times 10^{-2}$）20k 步	MMD^2（$\times 10^{-2}$）選出的預算
RBM	11	4.25 ± 1.40	1.59 ± 0.29	8.6 ± 0.8	5.3 ± 0.7
RBM	100	4.27 ± 3.01	1.16 ± 0.23	9.6 ± 2.6	5.4 ± 0.6
DCGAN	11	27.7 ± 33.6	1.11 ± 0.56	67.5 ± 50.3	5.5 ± 1.7
DCGAN	100	9.01 ± 1.22	0.55 ± 0.12	7.2 ± 1.7	2.0 ± 0.3

附錄 **F** 各類別樣本

圖 6 呈現表 4 中各類別執行所生成的內容，每個類別一列，來自表 2 的實驗組在每個類別內重新訓練；而在 N=11 時，同樣這三次執行的留出集投影相關達到 0.9227 ± 0.0014、0.9248 ± 0.0030 與 0.8986 ± 0.0032，對照合併實驗組的 0.9102 ± 0.0026。表 4 的每一列都與它自己的真實對真實下限比較，而不是與另一個類別比較；以該表的單位計，這些下限為 axion 0.032/0.36/0.31、cdm 0.034/0.30/0.32、no sub 0.035/0.45/0.45、合併 0.041/0.48/0.40，各自的標準差約為其平均值的一半。各列看起來相似，是因為三個類別只在幾個百分點的像素變異上有差別，所以我們主張的是每個類別都能各自被生成，而不是模型能把它們區分開來。

表 **4**：以表 2 的實驗組在 N=100 下做各類別生成，每一次執行都在單一類別內訓練與評分，並與合併訓練的實驗組對照；數值為跨五個隨機種子的平均值 ± 標準差，單位同表 2，標準差取到小數點後兩位，投影相關則取到小數點後四位。每個類別都有自己的下限，列於正文中。粗體的意義同表 2。

訓練集	PDF–JS（$\times 10^{-3}$）	MMD^2（$\times 10^{-2}$）	MMD$^2_{\mathrm{al}}$（$\times 10^{-2}$）	投影相關
僅 axion	2.84 ± 0.08	7.11 ± 0.22	2.08 ± 0.23	**0.9718** ± 0.0004
僅 cdm	2.77 ± 0.24	7.85 ± 0.19	1.84 ± 0.28	0.9688 ± 0.0004
僅 no sub	2.95 ± 0.32	7.99 ± 0.13	2.94 ± 0.27	0.9701 ± 0.0002
合併	*2.91* ± 0.28	*7.16* ± 0.29	*2.55* ± 0.44	*0.9684* ± 0.0004

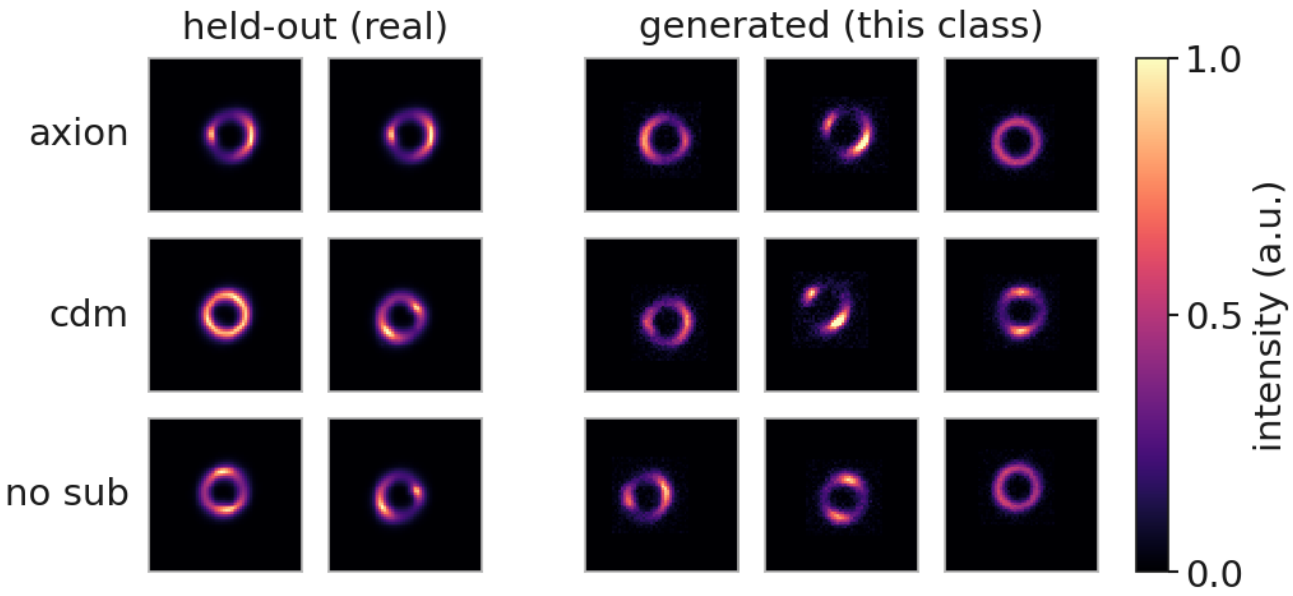


圖 **6**：各類別樣本。每一列為一個類別，先是兩張留出影像，接著是三張由僅以該類別 100 張影像訓練的實驗組所生成的影像，分別依索引順序取前兩張與前三張、未經挑選，使用共用的 0—1 色階。

翻譯說明

- 對應的英文原稿：`paper/ml4ps2026/v11/main.tex`（v11 投稿稿），圖檔取自 `paper/ml4ps2026/v11/figures/`。
- 翻譯日期：2026-09-09。
- 用途：供作者與合作者閱讀的中文版，非投稿用版本。逐段忠實翻譯，未增刪內容、未更動任何數字、未加入評論。
- 編號對應：圖 1（地圖與樣本）、圖 2（機制）、圖 3（管線流程）、圖 4（支撐集不匹配與上限）、圖 5（資料量縮放）、圖 6（各類別樣本）；表 1（地圖）、表 2（原論文式比較）、表 3（附錄 E 的固定 20k 步基準模型）、表 4（附錄 F 的各類別生成）。原文的 `\cite` 已改寫為 `[作者 年份]`。
- 與 **v10** 中文版的差異：v11 全面改為五個隨機種子的 mean ± sd（v10 為單一隨機種子），基準模型改用驗證集提前停止、下限改稱真實對真實下限，主張由「勝過基準」下修為「在 11 張影像時相當」，並新增表 3（固定 20k 步 vs 由驗證集選出的預算）。

固定譯法表

原文	譯法
IQP circuit	IQP 電路
instantaneous quantum polynomial	瞬時量子多項式
Born machine	Born machine
maximum mean discrepancy (MMD)	最大平均差異（MMD）
Walsh basis / Walsh order spectrum	Walsh 基底／ Walsh 階譜
correlation—complexity map	相關性—複雜度地圖
I_{QCLI} / I_{CCI}	保留符號
latent	潛變數
learned directions	學到的方向
held-out	留出集
projection correlation	投影相關
flux-aligned	通量對齊

原文	譯法
raw (metric)	未對齊
permutation null	置換零模型
i.i.d.-uniform null	獨立均勻零模型
reference paper	原論文
strong gravitational lensing	强重力透鏡
substructure	子結構
crop	裁切
pmf	機率質量函數（pmf）
seed	隨機種子
arm	實驗組
flat MMD / paper kernel	平坦 MMD ／原論文核
split-half floor	對半切分下限
real-vs-real floor	真實對真實下限
validation early stopping	驗證集提前停止
seed noise / seed spread	種子噪音／種子離散度
biased V-statistic	有偏 V 統計量
envelope	包絡線
coherence radius	同調半徑
trainability	可訓練性
support mismatch	支撐集不匹配
pre-registered	預先登錄
post-hoc	事後分析
warm start	暖啓動
restart	重啓
bin	分箱
bandwidth	頻寬